1. 執行環境

Jupyter Notebook

2. 程式語言 (請標明版本)

Python 3.7

3. 執行方式 (重要!!!!!!!)

以 Jupyter Notebook 執行

4. 作業處理邏輯說明

環境：

- import 套件，以及設定好檔案路徑
- pprint 只是讓 output 好看一些，不全部擠在一起

先把老師上課 ppt 中的程式架構列出，主要包含 Training Phase 跟 Testing Phase 照著裡面需要的功能一一列出

Training Phase

1. ExtractVocab

- ExtractVocab 的部分可以延續作業二，並且有回去看當時的檔案 output，盡可能把一些標點符號、一個 letter 的刪掉
- 另外本來還想把 url 刪掉，後來 feature select 的時候也會篩掉因此不另處理
- 上一次作業有個疏失，先 stem 了才 remove stopwords，導致部分 stopwords 沒有清乾淨，這次將順序對調，先 remove stopwords，最後才 stem
- 這次就不用 counter 函數了，因為老師給的程式架構當中要把每個 class 的 text 整合一起，因此先做 token 而已

2. CountDoc

- 這部分把作業 PA-3 中的 https://ceiba.ntu.edu.tw/course/88ca22/content/training.txt 網址擷取 class_id 跟 doc_id，還有各類別文件數、總數
- 最後因為要區分 testing data，所以也做了所有 training data 的 doc_id 清單

3. TEXTc <- ConcatenateTextOfAllDocsInClass(D, c)

- 按照每個類別的訓練文件，各自整合在一起
- 這邊原本要用上次 collection 套件的 counter 方法，計算 tf, df，但是後來聽助教說用 set()這個方法，感覺比較方便

  結果:

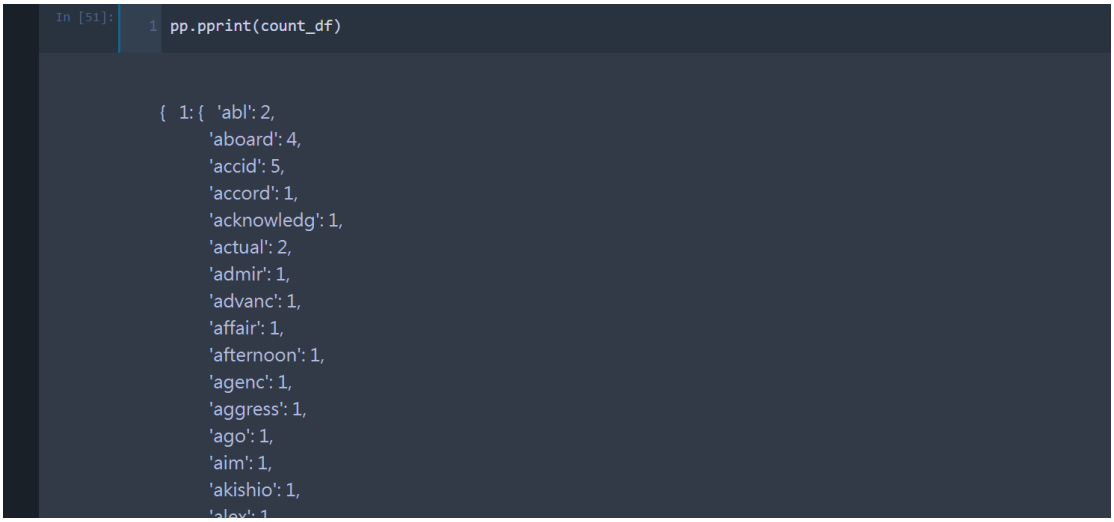

4. Feature Selection，採用 LLR(助教的建議，而且文獻指出 LLR 效果比 Chi square 好)

因為 Vocabulary 數量太過龐大，會有太多 noise，所以用 feature selection 挑出代表字，一樣先附上老師給的程式架構做為參考，並參考 PPT 的說明，得知需要的變數有 n11, n10, n01, n00, Pt, P1, P2, H1, H2

- 因為要從所有 training 文件中取得代表字，因此需要 Text_of_All_Docs 作為參數
- 計算 n11, n10, n01, n00 需要是有出現在 training doc 中的 term 的 df，因此需要 count_df[class_id][term]中的[df]
- 計算出每個 term 的 LLR 分數
- 把每個 class 都取出最高的前 number_of_feature 個代表字，取 38 的話全部代表字為 498，最為接近，39 的話則是 510。
- total_feature_maxnum 所有代表字加總最多 500
- train_class_doc_num 因為需要知道每個分類有多少訓練文件，以計算 n10, n00

5. 計算 Tctk, Tct', 以及每個 class 的 Prior, condprob

- 此例每個 class 都是 15 個訓練文件，因此 Prior 剛好都一樣
- condprob 每個代表字出現在該 class 的機率
- Tct = The total number of terms in D from class c.
- Tctk = The number of occurrences of tk in D from class c
- 代表字若有出現在該 class，則給他該代表字的 tf 值；若無，幫他+1 做 smoothing，Tct 則是所有出現在該 class 的代表字的 tf 值加總
- Tctk 則是指該代表字出現在該 class 的 tf 值

Testing Phase

- IRTM 中所有文件，但排除訓練文件，為測試資料
- 取出字做法如同 Training Phase
- 每個 class 的 Prior 分數取 log
- 計算該文件為各個 class 的可能性
  - 若該字在代表字中，將他該 class 的分數加上 condprob[class][term]的分數，持續加總到跑完該文章所有字

結果:

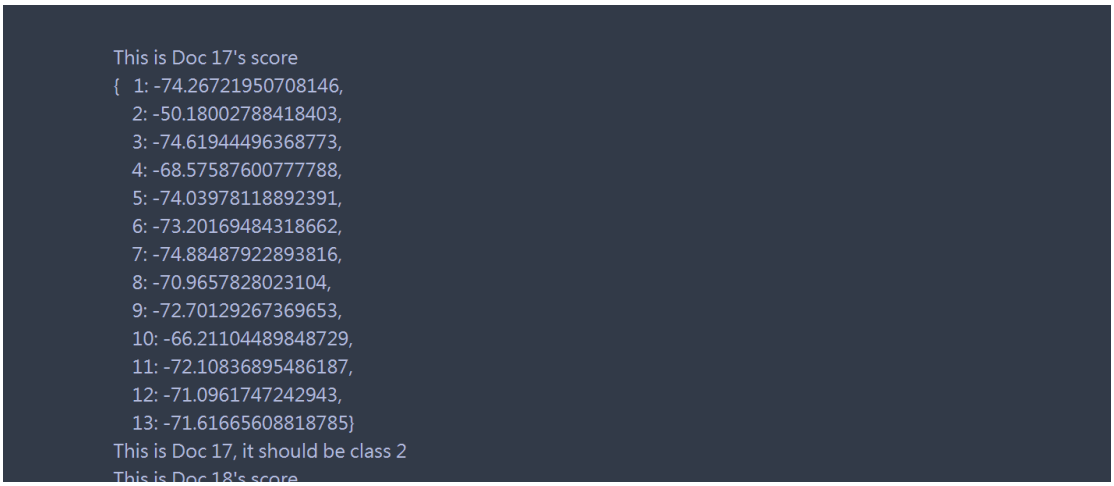

Write Result

轉為 dataframe，再用 to_csv 的方法寫成 result

心得：

每天寫一點程式都像在跑馬拉松，但是多謝于真助教那天的開示，知道方法步驟後可以開始的很快! 但是 prediction 的結果我真的大吃一驚！！其實比較想聽同學們其他 feature selection 的分享．．．